



Metodología para el monitoreo del tráfico urbano mediante visión por computadora

Bernardo Hernández Sánchez
César Jaime Montiel Moctezuma
Carlos Daniel Martner Peyrelongue
Ilse Cervantes Camacho

Publicación Técnica No. 914
Querétaro, México
2026

ISSN 0188-7297

Este trabajo de investigación se desarrolló en la Coordinación de Transporte Integrado y Logística (CTIL) del Instituto Mexicano del Transporte (IMT) por el Mtro. Bernardo Hernández Sánchez, con la participación del Dr. César Jaime Montiel Moctezuma, el Dr. Carlos Daniel Martner Peyrelongue y la Dra. Ilse Cervantes Camacho, del Centro de Investigación en Ciencia Aplicada y Tecnología Avanzada del IPN (CICATA-IPN) unidad Querétaro.

El presente documento corresponde al producto final del proyecto de investigación interna TI 07/25, titulado “Metodología para el modelado y predicción de la movilidad urbana con inteligencia artificial para la gestión del tráfico en Querétaro”, etapa 2.

Se agradece la colaboración del Dr. Juan Ramón Terven Salinas, del Centro de Investigación en Ciencia Aplicada y Tecnología Avanzada (IPN-CICATA Querétaro), por sus aportaciones técnicas y académicas, así como por la orientación brindada en la definición y consolidación del enfoque metodológico.

Asimismo, el primer autor de este documento, quien también es estudiante del Doctorado en Tecnología Avanzada del Instituto Politécnico Nacional, agradece el financiamiento otorgado por la Secretaría de Posgrado e Investigación del IPN al proyecto “Sistema Autónomo de Monitoreo del Tránsito Urbano para la Investigación Aplicada en Movilidad de Ciudades Intermedias” (Proyecto No. 20254782).

Las opiniones expresadas en esta publicación son de los autores(as) y no necesariamente reflejan los puntos de vista del Instituto Mexicano del Transporte.

Tabla de Contenido

	Página
Sinopsis.....	v
Abstract.....	vii
Introducción.....	1
1. Marco conceptual.....	5
1.1 Condiciones operativas del tráfico urbano y retos de medición.....	5
1.2 Observación continua para diagnóstico y trazabilidad.....	6
1.3 Visión por computadora como fuente de datos.....	6
1.4 Variables operativas para gestión del tráfico.....	8
1.4.1 Definiciones operativas mínimas.....	8
1.4.2 Eventos operativos y comportamiento observable.....	9
1.4.3 Relación entre variables y su uso en diagnóstico.....	10
1.5 Visión por computadora aplicada al monitoreo vial.....	11
1.5.1 Geometría del sitio y extracción de variables.....	12
1.5.2 Estructuración de resultados: eventos y trazabilidad.....	13
2. Metodología propuesta.....	15
2.1 Arquitectura de visión por computadora basada en el borde.....	16
2.1.1 Componentes y responsabilidades.....	16
2.1.2 Hardware del nodo en el borde.....	16
2.2 Extracción de variables operativas.....	17
2.2.1 Configuración geométrica: ROI y líneas virtuales.....	18
2.2.2 Detección vehicular (YOLOv8n) y filtrado por clases.....	19
2.2.3 Seguimiento multiobjeto y trayectorias.....	20

2.2.4	Estimación de velocidad mediante dos líneas de referencia.....	21
2.2.5	Detección de cambio de carril basada en geometría.....	22
2.2.6	Criterios temporales de validación del evento.....	23
3.	Resultados.....	25
3.1	Datos y diseño experimental.....	25
3.2	Desempeño del pipeline de detección y seguimiento	26
3.3	Prueba de operación continua	27
3.4	Resultados de aforo por carril mediante cruces de línea	29
4.	Limitaciones y alcance de los resultados.....	33
	Conclusiones.....	35
	Bibliografía	37

Sinopsis

La presente publicación técnica describe una metodología para el monitoreo del tráfico urbano mediante visión por computadora, orientada a transformar video en metadatos operativos trazables mediante detección y seguimiento de vehículos. Se presentan el contexto y marco conceptual, el proceso de adquisición y preprocesamiento, la instrumentación geométrica del sitio (ROI, líneas virtuales y separadores de carril) y la ingeniería de características para derivar conteos por carril, estimaciones de velocidad y eventos de cambio de carril. Asimismo, se detalla el flujo de inferencia y seguimiento, el esquema de generación, transmisión y almacenamiento de eventos (p. ej., JSON hacia un servidor central) y un diseño experimental. Finalmente, se incluyen consideraciones para operación en campo, criterios de reproducibilidad y líneas de trabajo futuro para mejorar la robustez ante variabilidad ambiental y operativa.

Abstract

This technical publication describes a methodology for urban traffic monitoring using computer vision, aimed at transforming video into traceable operational metadata through vehicle detection and tracking. It presents the context and conceptual framework, the data acquisition and preprocessing workflow, the geometric site setup (ROI, virtual lines, and lane delimiters), and feature engineering to derive lane-level counts, speed estimates, and lane-change events. It also details the inference and tracking pipeline, the event generation, transmission, and storage scheme (e.g., JSON to a central server), and an experimental design. Finally, it includes considerations for field operation, reproducibility criteria, and future work directions to improve robustness under environmental and operational variability.

Introducción

El monitoreo del tráfico urbano mediante visión por computadora se define en este documento como un proceso técnico para generar metadatos operativos a partir de video capturado por cámaras fijas, ya sean existentes o instaladas con fines de aforo, con el propósito de producir mediciones y eventos integrables a procesos institucionales de diagnóstico, seguimiento de desempeño, evaluación de intervenciones y operación cotidiana. Bajo este enfoque, el video se considera una fuente primaria cuyo valor se materializa cuando se transforma en salidas operativas comparables y trazables, con parámetros explícitos y estructuras de datos diseñadas para su consulta y análisis.

En términos funcionales, los sistemas de *traffic surveillance* descritos en la literatura reciente suelen organizarse en dos niveles: (i) un nivel de percepción, que incluye detección, clasificación y seguimiento de vehículos, y (ii) un nivel de inferencia operativa, orientado a estimar variables como velocidad y conteos por carril, así como a identificar comportamientos o eventos relevantes para la gestión vial. La implementación en campo está condicionada por restricciones típicas del entorno (iluminación variable, oclusiones, vibración y condiciones climáticas) y por la disponibilidad de cómputo para operar con latencias compatibles con los requerimientos del caso de uso (Matias et al., 2025; Zhou et al., 2025).

Con base en los resultados reportados en la Publicación Técnica del IMT No. 864 (Hernández et al., 2025), Con base en los resultados reportados en la Publicación Técnica del IMT No. 864 (Hernández et al., 2025), donde se establecen bases metodológicas para el uso de inteligencia artificial en el análisis y la predicción del tránsito vehicular en Santiago de Querétaro, el proyecto TI 07/25 se orientó a consolidar un enfoque operativo sustentado en la integración de datos urbanos y técnicas de IA para caracterizar patrones de circulación y generar insumos para la gestión vial. En este marco, la presente publicación técnica, titulada Metodología para el monitoreo del tráfico urbano mediante visión por computadora, documenta el procedimiento para obtener variables operativas a partir de analítica de video, con énfasis en la detección y seguimiento de vehículos, la estimación de parámetros (p. ej., velocidad y conteos), y la estructuración de resultados como eventos para su análisis, consulta y trazabilidad.

Si bien existen contribuciones relevantes sobre movilidad inteligente y modelado del tráfico, incluyendo modelos analíticos, enfoques de flujo continuo y esquemas de estimación del estado del tráfico a partir de sensores fijos, vehículos instrumentados y vehículos conectados, su adopción en contextos urbanos con alta variabilidad operativa requiere criterios de medición claramente definidos, procedimientos de instrumentación verificables y mecanismos que aseguren la reproducibilidad de los resultados. En consecuencia, este documento plantea un enfoque de monitoreo basado en visión por computadora orientado a la obtención sistemática de metadatos operativos y eventos estructurados, diseñado para su incorporación a procesos institucionales de análisis y soporte a la gestión vial.

En particular, se propone una metodología reproducible para implementar un sistema de monitoreo basado en video que entregue metadatos trazables (p. ej., conteos por carril, velocidades estimadas y eventos como cambios de carril) a partir de secuencias de video, con énfasis en decisiones de instrumentación (ROI y líneas virtuales), arquitectura de procesamiento en borde y criterios de evaluación. La metodología se enfoca en: (i) cámaras monoculares fijas orientadas a una sección vial urbana (arteriales, avenidas o accesos controlados) y configuradas para observación continua; (ii) extracción de variables por carril o por zona mediante ROI, líneas virtuales y reglas geométricas; y (iii) integración operativa bajo el principio “*video in → metadatos out*”, priorizando el envío de eventos e indicadores sobre la transmisión continua de video (Barthélemy et al., 2019; Wright et al., 2022b).

Supuestos operativos. Se asume que: (a) existe una vista estable del tramo (montaje mecánico con vibración controlada y encuadre suficientemente constante), y (b) la escena permite definir una ROI y líneas de referencia consistentes a lo largo del periodo de operación. En la literatura reciente, la calibración de cámaras para fines de medición se reconoce como un factor determinante para asegurar comparabilidad entre campañas y para interpretar el origen de los errores en condiciones reales de campo (Macko et al., 2025; Vuong et al., 2019).

Casos de uso típicos. (i) Aforo (*counts*): conteo por carril o por movimiento, agregado en ventanas temporales (p. ej., 1–5 min) y sustentado en detección y seguimiento. (ii) Velocidad: estimación a partir de trayectorias y un mapeo píxel→mundo (o mediante dos líneas de referencia con distancia conocida), reportada por vehículo y/o agregada por intervalos. (iii) Eventos: cambios de carril (basados en geometría), detenciones anómalas u otros eventos definidos mediante reglas sobre trayectorias. Estos casos se alinean con la categorización vigente de sistemas de

vigilancia de tráfico, donde la extracción de parámetros (conteo/velocidad) y la identificación de comportamientos dependen de la confiabilidad de la detección y el seguimiento en condiciones no controladas (Matias et al., 2025; Zhou et al., 2025).

El documento se organiza en 4 capítulos. En el Capítulo 1 se presenta el contexto del problema y el marco conceptual relacionado con el monitoreo del tráfico urbano y el uso de visión por computadora. En el Capítulo 2 se describe la metodología de investigación propuesta y aplicada donde se describe las fuentes de datos, la adquisición de video y el preprocesamiento requerido para su análisis, también se detalla la instrumentación geométrica del sitio (ROI y líneas virtuales) y la ingeniería de características para la obtención de variables operativas. El Capítulo 3 expone los resultados obtenidos de la aplicación de la metodología y del análisis de la información obtenida en el nodo con los aforos reales de la zona de estudio. Finalmente, el Capítulo 4 se presenta un análisis de las limitaciones identificadas en la aplicación de la investigación, así como los alcances de los resultados.

1. Marco conceptual

Este capítulo expone el problema operativo que motiva la necesidad de un monitoreo integral del tráfico urbano y establece un marco conceptual para posicionar la visión por computadora como una herramienta para generar información confiable y consistente para la gestión de la movilidad. Se delimitan dos ejes: (i) las condiciones del entorno urbano que limitan la gestión vial cuando se basa en observaciones parciales o no comparables, y (ii) los metadatos operativos necesarios para el diagnóstico, el seguimiento y la evaluación del desempeño, orientados a fortalecer la toma de decisiones y la eficiencia en la operación del sistema vial.

1.1 Condiciones operativas del tráfico urbano y retos de medición

La operación vial urbana se caracteriza por alta variabilidad temporal, heterogeneidad de la demanda y la presencia de perturbaciones no recurrentes (National Academies of Sciences, 2022). En escalas horarias se observan cambios pronunciados asociados a horas pico, entradas y salidas escolares, ventanas de carga y descarga, y actividad comercial; mientras que, en escalas de minutos, predominan interacciones locales (paradas, incorporaciones, bloqueos parciales) y efectos del control de tránsito (ciclos semafóricos, prioridad al transporte público y restricciones de giro) (Xing et al., 2022a). En conjunto, estas dinámicas generan transiciones frecuentes entre estados de flujo relativamente estable y estados con formación y disipación de colas, lo que dificulta el diagnóstico y la comparación del desempeño cuando no se cuenta con mediciones consistentes en el tiempo y el espacio.

A lo anterior se suman eventos no recurrentes (incidentes, fallas en el señalamiento, obras y lluvia intensa) que modifican la capacidad efectiva, alteran patrones de cambio de carril y degradan la regularidad de la operación. En este contexto, una gestión basada únicamente en mediciones puntuales puede omitir fenómenos relevantes, como la formación de colas aguas arriba, bloqueos por retroceso (*spillback*) o la propagación de la congestión (Thabit et al., 2024). Por ello, en enfoques contemporáneos de gestión y monitoreo se reconoce la necesidad de instrumentación que permita observar, estimar e integrar estados de

tráfico con mayor cobertura espacial y consistencia temporal, de manera que los diagnósticos y evaluaciones se sustenten en evidencia comparable entre periodos y condiciones operativas.

1.2 Observación continua para diagnóstico y trazabilidad

La observación continua no se reduce a “tener más datos”, sino a capturar evidencia suficiente para (a) detectar cambios de régimen (flujo libre → congestionado), (b) identificar cuellos de botella, (c) sustentar atribuciones plausibles de causa (control, incidentes, demanda) y (d) cuantificar efectos operativos (colas, retrasos y confiabilidad). En la práctica, estas tareas dependen de variables macroscópicas (flujo, velocidad, densidad/ocupación) y de variables operativas a nivel de sitio (colas por carril, bloqueos por retroceso, saturación de fases, cambios de carril y conflictos), particularmente cuando la observación es parcial y está sujeta a ruido o cobertura incompleta (Seo et al., 2017; Xing et al., 2022a).

La trazabilidad implica que cada variable reportada pueda reconstruirse a partir de: (i) su definición operativa, (ii) el método de medición/estimación, (iii) parámetros explícitos (p. ej., geometría, ROI, líneas virtuales, unidades, ventanas temporales) y (iv) reglas de control de calidad (p. ej., filtrado de outliers, manejo de oclusiones). Esta trazabilidad resulta clave cuando los datos se usan para auditoría de desempeño, validación de modelos, comparabilidad entre periodos y soporte a decisiones. Las revisiones recientes en estimación de estado de tráfico enfatizan que, ante datos incompletos o heterogéneos, la confiabilidad de la toma de decisiones depende de definiciones claras y de procesos reproducibles de estimación (Xing et al., 2022b; J. Zhang, Mao, et al., 2024).

1.3 Visión por computadora como fuente de datos

La alta variabilidad espacio-temporal de la operación urbana y la presencia de perturbaciones no recurrentes dificultan el diagnóstico y la comparación del desempeño cuando no se cuenta con mediciones consistentes en el tiempo y el espacio. En consecuencia, la instrumentación para gestión vial requiere observación continua y trazabilidad de variables, de modo que los indicadores reportados puedan interpretarse, auditarse y reproducirse con definiciones y procedimientos explícitos (Seo et al., 2017; Xing et al., 2022b; J. Zhang, Huang, et al., 2024)

En este marco, los sistemas de videovigilancia y cámaras viales constituyen una infraestructura extendida en entornos urbanos. La visión

por computadora permite transformar video en mediciones estructuradas (conteos, trayectorias, velocidades, colas y ocupación aproximada) mediante una cadena típica de procesamiento: *detección* → *seguimiento multiobjeto* → *asociación a carriles/ROI* → *extracción de variables* → *generación de eventos y agregados*. Revisiones recientes describen este enfoque como *visual traffic surveillance* y discuten su adopción en monitoreo y gestión, señalando retos técnicos (oclusiones, variación de iluminación, perspectiva y clima) y necesidades de evaluación (exactitud por clase, consistencia de identidades e incertidumbre/errores en velocidad y conteo) (Ghahremannezhad et al., 2023; X. Zhang et al., 2022).

Metodológicamente, el enfoque se apoya en detectores modernos (p. ej., familias YOLO) para localizar vehículos y en rastreadores *tracking-by-detection* para mantener identidades en el tiempo, lo que habilita el cálculo de trayectorias y métricas derivadas (tiempos de cruce, velocidades, permanencias y eventos inferidos mediante cruces de líneas virtuales o transiciones entre regiones/carriles). En la literatura reciente se reportan como opciones representativas ByteTrack y BoT-SORT dentro del ecosistema de *multi-object tracking* (MOT) (Aharon et al., 2022; Wang et al., 2023; Y. Zhang et al., 2022). Desde una perspectiva operativa, cuando el objetivo es la gestión vial, el producto principal no es el video, sino los metadatos: series temporales por carril, eventos con sello de tiempo y agregados por ventanas de análisis. Esto favorece *esquemas edge-servidor* orientados a reducir costos de red y exposición de información sensible, al transmitir registros estructurados en lugar de flujos continuos de video (X. Zhang et al., 2022).

Esto motiva una arquitectura *cámara-edge-servidor* en la que el nodo en borde implementa el pipeline¹ y publica metadatos estructurados (eventos y agregados) bajo un contrato de datos versionado, asegurando trazabilidad, comparabilidad entre periodos y operación continua. En términos de gestión vial, esta capacidad de convertir video en metadatos operativos (eventos y agregados) solo resulta comparable y auditable si las variables derivadas se definen con precisión, unidad, ventana temporal y ámbito espacial, y si su estimación se documenta de manera reproducible. Con base en ello, el siguiente apartado establece las variables operativas mínimas a reportar y sus definiciones para análisis consistente entre periodos y sitios.

¹ Es una secuencia estructurada de etapas donde la salida de una fase se convierte en la entrada de la siguiente, con el objetivo de procesar datos, código o eventos de manera ordenada, reproducible y automatizada

1.4 Variables operativas para gestión del tráfico

A partir de las salidas de eventos y agregados generadas por el sistema de visión por computadora, se seleccionan variables orientadas a diagnóstico, seguimiento y soporte a decisiones operativas, priorizando definiciones mínimas que permitan comparabilidad temporal y espacial.

1.4.1 Definiciones operativas mínimas

Para asegurar la comparabilidad entre periodos de observación y la consistencia del análisis, en este trabajo se adoptan definiciones operativas mínimas para las variables de monitoreo vial derivadas de video, especificando su unidad, ventana temporal de agregación y ámbito espacial (por carril, por movimiento o por zona/ROI). En un marco mínimo, el estado del tránsito se caracteriza mediante: **flujo** q (vehículos por unidad de tiempo), **velocidad** v (por vehículo o agregada por intervalo) y una medida de **acumulación**, expresada como **densidad** k cuando existe calibración suficiente o, en su defecto, como **ocupación** occ o una aproximación dependiente del sitio y del método. Estas variables se emplean tanto para diagnóstico como para seguimiento y son consistentes con revisiones recientes sobre estimación del estado del tráfico en redes urbanas (Xing et al., 2022c).

- **Flujo (q):** número de vehículos que cruzan una sección de control por unidad de tiempo (p. ej., veh/h). Variable base para caracterizar demanda y evaluar desempeño por carril, movimiento o aproximación (Federal Highway Administration, 2016).
- **Velocidad (v):** puede definirse como velocidad puntual (instantánea) o como velocidad de recorrido entre dos referencias espaciales. En monitoreo con video, suele estimarse como razón distancia/tiempo entre líneas virtuales cuando existe una distancia de referencia documentada.
- **Densidad u ocupación (k/occ):** la densidad representa vehículos por unidad de longitud; la ocupación se define como la proporción de tiempo con presencia detectada (sensores puntuales) o como porcentaje de área ocupada en una región, según el método. En video, aproximaciones equivalentes pueden derivarse de presencia/tiempo en una ROI o inferirse a partir de conteos y velocidades bajo supuestos explícitos (Federal Highway Administration, 2016).
- **Colas:** longitud o número de vehículos en espera asociada a un punto de conflicto (intersección, estrechamiento o acceso

controlado). En visión por computadora puede aproximarse mediante la detección de vehículos detenidos y la estimación de su extensión espacial dentro del tramo instrumentado (Umair et al., 2021).

- **Eventos:** ocurrencias discretas con significado operativo, por ejemplo: cruce de línea de conteo, entrada/salida de ROI, cambio de carril, detención prolongada, invasión de carril o presencia de objeto atípico. Los eventos permiten reconstruir comportamiento a nivel micro (por vehículo) y, a partir de ellos, generar agregados por periodo con reglas reproducibles.

Estas variables se utilizan para el diagnóstico del desempeño (identificación de recurrencia, patrones por carril y condiciones de saturación), el seguimiento (comparación entre periodos y evaluación de intervenciones) y el soporte a la toma de decisiones (priorización de atención operativa) (Xing et al., 2022c; J. Zhang, Mao, et al., 2024). En el marco de manuales de capacidad y desempeño multimodal, se vinculan con indicadores como retraso, nivel de servicio y confiabilidad, así como con fenómenos operativos relevantes, entre ellos la saturación y el derrame de cola (*queue spillback*) en sistemas arteriales y redes coordinadas (National Academies of Sciences, 2022).

1.4.2 Eventos operativos y comportamiento observable

Además de variables agregadas, la gestión vial requiere eventos discretos que funcionen como marcadores operativos para reconstruir lo observado a nivel micro y derivar agregados por ventana con reglas explícitas. En sistemas basados en visión, estos eventos suelen derivarse de trayectorias (*tracking*) y de su interacción con geometrías de referencia (líneas virtuales, límites de ROI y regiones de carril) (Kim et al., 2023).

- **Entrada/salida de ROI:** transición de una trayectoria respecto al polígono de una región instrumentada (p. ej., *entry* cuando el centroide cruza el borde hacia el interior; *exit* cuando cruza hacia el exterior). Permite métricas como presencia, permanencia y tiempos de recorrido dentro de la zona (Abdelhalim & Abbas, n.d.).
- **Eventos de paso (crossings):** cruce de líneas virtuales (por carril o movimiento) para aforo, headways y tiempos entre referencias espaciales; se registran con sello de tiempo y referencia (línea/carril/movimiento) (Shokrolah & Morris, 2016).
- **Cambios de carril:** transición sostenida de la trayectoria entre regiones asociadas a carriles (o cruce de separadores/líneas laterales

virtuales), idealmente con histéresis temporal para evitar “rebotes” por ruido/oclusiones. Son relevantes por su relación con fricción/turbulencia del flujo y con comportamientos de riesgo (Czapla, 2020).

- **Incidentes o anomalías operativas:** ocurrencias fuera del patrón esperado (p. ej., vehículo detenido anómalo, obstrucciones temporales, congestión atípica, exceso de velocidad según regla y calibración). Su definición debe explicitar umbrales, ventana temporal y condiciones de activación (Liang et al., 2022).

En línea con revisiones de vigilancia visual, conviene evaluar estos eventos por escenario (día/noche, lluvia, congestión, oclusión) y documentar definiciones reproducibles para comparabilidad y auditoría (Kim et al., 2023).

1.4.3 Relación entre variables y su uso en diagnóstico

En términos de diagnóstico, las variables descritas se emplean para:

1. **Caracterizar el estado operativo:** la velocidad v y el flujo q permiten identificar degradación del desempeño, mientras que la densidad/ocupación k/occ y las colas describen la acumulación y la proximidad a condiciones de saturación, incluyendo la posibilidad de derrame de cola (*spillback*) cuando existen restricciones aguas abajo (Zhang, et al., 2024).
2. **Localizar cuellos de botella:** patrones persistentes de baja velocidad y alta acumulación en tramos específicos, junto con colas recurrentes en aproximaciones, orientan la identificación de causas probables asociadas a geometría, control, fricción por giros e interferencias locales (p. ej., paradas o accesos) (Xing et al., 2022b).
3. **Distinguir fenómenos recurrentes y no recurrentes:** cambios abruptos en la tasa de eventos (p. ej., detenciones atípicas, obstrucciones) y desviaciones respecto a patrones base en series temporales apoyan la detección y clasificación de incidentes o perturbaciones operativas (Thabit et al., 2024).
4. **Evaluar intervenciones:** la comparación antes/después debe realizarse con ventanas equivalentes y parámetros consistentes (misma ROI y líneas virtuales, mismas reglas de filtrado y umbrales) para atribuir cambios a ajustes de control u operación.

En este marco, la visión por computadora se entiende como un medio para instrumentar variables operativas con cobertura suficiente para soportar procesos de gestión, incluyendo monitoreo en tiempo casi real, analítica histórica, evaluación de desempeño y generación de evidencia con trazabilidad.

1.5 Visión por computadora aplicada al monitoreo vial

La visión por computadora aplicada al monitoreo vial emplea video como insumo para extraer información operativa mediante detección y, cuando corresponde, seguimiento multiobjeto (MOT). En implementaciones actuales, el flujo de procesamiento se formula como un esquema de detección por cuadro + asociación temporal para construir trayectorias y, a partir de ellas, estimar variables y eventos operativos. Revisiones recientes sistematizan este enfoque para el caso vehicular y señalan la necesidad de criterios consistentes en algoritmos, datos y evaluación para facilitar comparabilidad entre estudios (Matias et al., 2025).

Para asegurar comparabilidad, la evaluación suele apoyarse en benchmarks y métricas estandarizadas de seguimiento, que distinguen errores de localización, asociación e identidades. Entre las referencias base se encuentran las métricas CLEAR MOT (p. ej., MOTA/MOTP), y propuestas posteriores como HOTA, que buscan balancear detección y asociación en un indicador único, además de marcos de evaluación tipo MOTChallenge/MOT16 (Bernardin & Stiefelwagen, 2008).

En la práctica, la detección de objetos en escenarios ITS suele apoyarse en detectores single-stage de la familia YOLO por su viabilidad para operación en tiempo casi real y su adopción amplia en tareas de vigilancia/monitoreo. En esta línea, YOLOv7 documenta explícitamente el objetivo de desempeño en tiempo real y su evaluación comparativa en detección (Wang et al., 2023). En aplicaciones ITS recientes se reporta el uso de YOLOv8 para detección vehicular orientada a monitoreo (p. ej., plataformas UAV/ITS) . Para YOLOv8, la trazabilidad suele apoyarse en la documentación y el repositorio del desarrollador, especificando versión, configuración y parámetros de inferencia reportados (Bakirci, 2024).

Cuando se requiere continuidad temporal a nivel vehículo, un enfoque recurrente consiste en: (a) detectar vehículos por cuadro, (b) asociar detecciones entre cuadros mediante un método de seguimiento tracking-by-detection (p. ej., SORT/DeepSORT) y (c) derivar variables operativas y eventos a partir de trayectorias y referencias geométricas del sitio (líneas o zonas/ROI) (Wojke et al., 2017). En particular, existen

implementaciones documentadas que combinan detección y seguimiento para conteo y estimación de velocidad por ROI, lo cual es coherente con un esquema de salidas basado en eventos y agregados (Chen et al., 2023).

Para asegurar comparabilidad entre periodos y trazabilidad de resultados, el monitoreo vial basado en visión por computadora debe acompañar cada variable y evento con la información mínima que permita reconstruir su proceso de obtención. En particular, se requiere documentar: (i) la versión del modelo y del pipeline (detección, seguimiento y reglas), (ii) la configuración de inferencia y postproceso, (iii) la definición geométrica del sitio (ROI y líneas virtuales, incluyendo su versión), y (iv) los criterios de control de calidad aplicados. Esta práctica reduce ambigüedad en la interpretación de métricas, facilita auditorías técnicas y permite atribuir cambios observados a variaciones operativas o a cambios en el sistema de medición.

En consecuencia, las salidas del sistema se estructuran como registros de eventos (ocurrencias discretas con sello de tiempo) y agregados (resúmenes por ventana), ambos bajo un contrato de datos versionado que define campos obligatorios, unidades, ámbito espacial y reglas de validación.

1.5.1 Geometría del sitio y extracción de variables

La extracción de variables a partir de video requiere vincular el plano de imagen con una representación operativa del sitio. Esto suele implementarse mediante: (i) una región de interés (ROI) que delimita el área de análisis y reduce interferencias, y (ii) referencias geométricas (líneas virtuales, separadores de carril, zonas de cruce) que permiten definir reglas de conteo y eventos (p. ej., cruces de línea) de manera consistente y reproducible. En aplicaciones de conteo, por ejemplo, es común el uso de count-lines (líneas virtuales) para contabilizar trayectorias que las intersectan, e incluso se han propuesto variantes adaptativas/no lineales para reducir errores por oclusiones e iluminación nocturna (Iwao et al., 2025; Vasu et al., 2021).

Para la estimación de velocidad con cámara monocular, el reto central es convertir desplazamientos en píxeles a unidades métricas, controlando perspectiva, escala y oclusiones. Un marco útil (y ampliamente reportado) es agrupar los enfoques en: (a) métodos con calibración/homografía explícita (o calibración basada en geometría de la escena), (b) métodos con autocalibración mediante puntos de fuga (vanishing points) y (c) enfoques que incorporan geometría 3D (p. ej., modelos/cajas 3D del vehículo o del plano vial) para estabilizar la conversión métrica. Esta

taxonomía y sus métricas/datasets se resumen en la revisión de Fernández Llorca et al. (Fernández et al., 2021). Como ejemplos representativos: Revaud & Humenberger proponen calibración robusta para CCTV usando únicamente un detector (sin requerir video “limpio”), orientada a escenarios reales de vigilancia; Kocur & Ftáčnik exploran calibración basada en pares de vanishing points asociados a vehículos; y Macko et al. plantean una variante eficiente basada en geometría de vanishing points y cajas 3D derivadas de detecciones 2D, evaluada con foco en desempeño/tiempo real (Kocur & Ftáčnik, 2021; Revaud & Humenberger, n.d., 2021).

1.5.2 Estructuración de resultados: eventos y trazabilidad

Para fines de integración y análisis, las salidas del sistema de visión por computadora se representan como eventos (p. ej., detecciones, cruces de línea, estimaciones de velocidad, cambios de carril) y agregados por ventana temporal, serializados en JSON conforme al estándar del formato. Este enfoque desacopla la generación de variables (nodo de procesamiento) de su almacenamiento y explotación (servidor/plataforma), y facilita consulta por periodos, auditoría y cálculo reproducible de indicadores (International Organization for Standardization, 2017).

La trazabilidad se operacionaliza mediante un contrato de datos que explicita: versión del esquema, versión del pipeline/modelo, parámetros de inferencia, definición geométrica (ROI y referencias), unidades y ventanas de agregación. Para ello, resulta útil validar la estructura de los eventos mediante JSON Schema (vocabularios de validación), lo que estandariza campos mínimos, tipos de datos y reglas básicas de consistencia (Wright et al., 2022a).

En aplicaciones con requerimientos de latencia y costos de red acotados, se privilegia procesar cerca de la fuente y publicar metadatos (eventos/agregados) en lugar de transmitir video de forma continua, reduciendo consumo de ancho de banda y latencia frente a enfoques centrados en nube (Hu et al., 2023).

2. Metodología propuesta

El insumo principal para el monitoreo del tráfico urbano mediante visión por computadora es el flujo de video proveniente de una cámara de infraestructura (p. ej., cámara IP fija vía RTSP). A partir de esta secuencia se ejecuta un pipeline de analítica visual para derivar detecciones por cuadro, trayectorias por vehículo (cuando se aplica seguimiento multiobjeto) y, con base en reglas geométricas del sitio (ROI y líneas virtuales), variables operativas como aforo/flujo, velocidad y métricas complementarias asociadas a trayectorias y eventos. Este enfoque se apoya en antecedentes consolidados de vigilancia vial basada en visión por computadora y medición a partir de video.

De forma complementaria, el sistema requiere metadatos de contexto para asegurar la trazabilidad e interpretación operacional de las mediciones. Como mínimo, se registran: identificador del sitio (`site_id`), identificador de cámara (`camera_id`), sentido(s) de circulación, número de carriles instrumentados, periodo de observación (inicio/fin) y la configuración geométrica vigente (versión de ROI y líneas virtuales, y su correspondencia con carril/movimiento). Cuando se incorpora almacenamiento en servidor, se recomienda registrar además metadatos de operación (p. ej., mantenimiento, reencuadre, reinicios, pérdidas de señal, cambios de iluminación severos) para explicar variaciones en la calidad del insumo y sustentar auditoría de resultados.

Metadatos mínimos recomendados (lista operativa)

- **Identificación:** `site_id`, `camera_id`, `edge_id` (si aplica)
- **Contexto vial:** sentido, carriles/movimientos instrumentados, ubicación/descripción breve
- **Ventana temporal:** `window_start`, `window_end`, zona horaria/UTC
- **Geometría vigente:** `roi_version`, `line_version`, IDs de ROI/líneas y su mapeo a carril/movimiento
- **Bitácora operativa:** eventos de mantenimiento, reencuadre, reinicios, degradación del stream (fps/resolución)

2.1 Arquitectura de visión por computadora basada en el borde

En esta sección se describe la arquitectura de visión por computadora basada en el borde adoptada para convertir flujos de video en metadatos operativos con trazabilidad, separando explícitamente las funciones de adquisición (cámara), procesamiento local (nodo edge) y consumo institucional (servidor/plataforma). El enfoque en borde se justifica por requerimientos típicos de operación en campo: latencia controlada, reducción de ancho de banda al priorizar eventos y agregados sobre transmisión continua de video, y robustez ante variaciones de conectividad mediante mecanismos de almacenamiento temporal y reenvío. Asimismo, facilita criterios de gobernanza del dato, incluyendo minimización, control de acceso y registro de configuración (p. ej., versiones de ROI, líneas virtuales y parámetros del pipeline).

A partir de esta arquitectura se detalla el flujo de procesamiento (ingesta/decodificación, inferencia, seguimiento, analítica y agregación), la pila de hardware y software considerada, y el esquema de salidas (eventos y agregados) como contrato de datos para integración institucional y evaluación de desempeño.

2.1.1 Componentes y responsabilidades

La arquitectura se organiza en tres componentes con responsabilidades diferenciadas: (i) la cámara como fuente del flujo de video y su configuración operativa, (ii) el nodo edge como capa de procesamiento local para convertir video en eventos y agregados, y (iii) el servidor/plataforma como capa de recepción, validación, almacenamiento y explotación de metadatos para consulta y evaluación.

En este esquema, la cámara entrega un stream con parámetros definidos (codec, fps, resolución, timestamp), el edge ejecuta el pipeline (decodificación, inferencia, tracking, reglas y agregación) y publica salidas estructuradas bajo un contrato versionado, mientras que el servidor concentra funciones de integración (API/broker), control de calidad, trazabilidad y visualización/analítica histórica.

2.1.2 Hardware del nodo en el borde

La inferencia en borde se ejecutó en una mini PC MSI Cubi 5 12M con Intel Core i3-1215U (hasta 4.4 GHz), operando solo en CPU, y conectada a una cámara IP tipo domo Dahua mediante un flujo RTSP. La Figura 2.1 resume el flujo de procesamiento desde la adquisición del video en la cámara, su análisis en el *nodo edge* y la generación y envío de metadatos (eventos y

agregados) hacia la plataforma institucional para almacenamiento, consulta y explotación analítica.




Figura 2.1 Arquitectura de visión artificial en el borde para monitoreo del tráfico urbano

Fuente: Elaboración propia.

La pila de software consideró Ubuntu 24.04.3 LTS como sistema operativo, junto con Python 3.11, Ultralytics YOLOv8 y OpenCV para la ingesta/decodificación y el procesamiento de video.

2.2 Extracción de variables operativas

La extracción de variables corresponde a la etapa en la que el video ya decodificado se transforma en mediciones cuantificables que describen el estado del tránsito. A partir de las detecciones por cuadro y su asociación temporal mediante seguimiento, se derivan atributos geométricos y dinámicos, por ejemplo: posición y trayectoria, conteos por carril, cambios de carril y estimaciones de velocidad. De forma complementaria, se generan indicadores de calidad y trazabilidad (p. ej., confianza, consistencia temporal de identidades, banderas de oclusión) necesarios para asegurar comparabilidad entre periodos y sitios. Estas variables constituyen la base para la analítica posterior, la agregación por intervalos y la generación de eventos estructurados que alimentan la plataforma de monitoreo.

2.2.1 Configuración geométrica: ROI y líneas virtuales

La configuración de la región de interés (ROI) y de las líneas virtuales define el marco espacial con el que se interpretan detecciones y trayectorias. La ROI delimita el área válida de análisis, en este caso, la sección operativa de los carriles, y permite descartar el resto de la imagen para reducir ruido y carga computacional; cuando aplica, se incorporan máscaras de exclusión para eliminar zonas no pertinentes. Sobre esta ROI se establecen referencias geométricas (divisores de carril, umbrales laterales, límites superior e inferior), así como líneas de cruce y/o líneas de referencia para velocidad, especificando su sentido de circulación.

La Figura 2.2 muestra la interfaz de configuración geométrica utilizada para delimitar la ROI, definir umbrales y establecer separadores de carril y referencias (líneas/zonas) asociadas al sentido de circulación. Esta configuración se versiona y se registra como parte de la trazabilidad del pipeline, ya que determina las reglas de conteo, eventos y la conversión métrica (p. ej., mediante una distancia de referencia). En la interfaz se definen los siguientes elementos:

- **Umbrales** (superior, inferior, izquierdo, derecho): delimitan el “marco” válido dentro del plano de imagen (útil para descartar zonas no pertinentes).
- **Divisor camino y divisores de carril 1–6**: referencias geométricas para particionar la ROI por carriles.
- **ROI**: selección/ajuste del polígono o región de análisis.
- **Sentido**: define la dirección de circulación (para reglas de cruces, conteo y velocidad).
- **Parámetros**: metros = 30 (distancia de referencia para conversión métrica) y carriles = 3 (cantidad instrumentada en el sitio).

UMBRAL SUPERIOR	UMBRAL DERECHO
UMBRAL INFERIOR	UMBRAL IZQUIERDO
DIVISOR CAMINO	
DIVISOR CARRIL 1	DIVISOR CARRIL 4
DIVISOR CARRIL 2	DIVISOR CARRIL 5
DIVISOR CARRIL 3	DIVISOR CARRIL 6
ROI	SENTIDO
metros: 30	carriles: 3

Figura 2.2 Interfaz de configuración geométrica: ROI, umbrales, divisores de carril y parámetros de referencia

Fuente: Elaboración propia.

Una vez definidos y versionados la ROI, los umbrales, los divisores y el sentido, estas referencias se emplean como instrumentación del sitio: permiten transformar detecciones y trayectorias en variables operativas mediante reglas reproducibles (cruces de línea, transiciones entre carriles y medición entre referencias). En la Figura 2.3 se muestran la ROI, los umbrales y los divisores de carril utilizados para instrumentar el sitio; estas referencias sustentan las reglas de conteo, asignación de carril y estimación de velocidad. A partir de estas referencias geométricas, el sistema registra eventos operativos (p. ej., conteos por cruce de línea, trayectorias, cambios de carril y estimaciones de velocidad) cuando los vehículos intersectan las líneas y/o transitan entre regiones definidas. Para robustecer la medición, se parametrizan bandas de tolerancia y zonas de disparo asociadas a cada línea/ROI, así como el mapeo carril-región, con el fin de reducir activaciones fuera de escena, asegurar una asignación consistente de carril y garantizar que las mediciones sean comparables y trazables entre distintas sesiones de operación.




Figura 2.3 Instrumentación geométrica del sitio: ROI, umbrales y divisores de carril para conteo, seguimiento y estimación de velocidad

Fuente: Elaboración propia.

2.2.2 Detección vehicular (YOLOv8n) y filtrado por clases

La detección vehicular se realiza por cuadro a partir del flujo de video adquirido desde la cámara mediante RTSP. Para este fin se emplea YOLOv8n (Ultralytics) con pesos preentrenados en MS COCO (sin ajuste fino), generando como salida, para cada cuadro, un conjunto de detecciones compuestas por caja delimitadora, clase y puntuación de confianza (Lin et al., 2015; Ultralytics, 2023). La inferencia se configura con

entrada *letterbox* de 640 px, umbral de confianza $\tau = 0.25$ y supresión no máxima (NMS) con IoU $\theta = 0.70$.

Con el propósito de adaptar el detector al contexto operativo, la salida se restringe a clases vehiculares relevantes para el análisis (p. ej., automóvil, motocicleta, autobús y camión). Este filtrado reduce detecciones fuera de interés (peatones, mobiliario, vegetación u otros objetos) y estabiliza el flujo de datos hacia los módulos posteriores (seguimiento, conteos y eventos). Para trazabilidad, se registran la versión del modelo/pesos, los parámetros de inferencia y la configuración geométrica vigente (ROI y líneas).

2.2.3 Seguimiento multiobjeto y trayectorias

A partir de las detecciones por cuadro, se implementa un esquema de seguimiento multiobjeto (*tracking-by-detection*) para asociar detecciones entre cuadros consecutivos y construir trayectorias por vehículo. En este enfoque, el rastreador asigna un identificador temporal (*track_id*) y mantiene la continuidad de identidad durante la permanencia del vehículo dentro de la ROI, resolviendo correspondencias con base en criterios como superposición geométrica (IoU), consistencia temporal y manejo de oclusiones (Bewley et al., 2016; Wojke et al., 2017).

El producto de este módulo es un conjunto de trayectorias $\{(x_t, y_t)\}$ o secuencias de cajas por *track_id*, a partir de las cuales se derivan variables y eventos:

- **Trayectorias y posiciones** dentro de la ROI (por cuadro o muestreadas).
- **Asignación por carril/ región** mediante la intersección de la trayectoria con particiones geométricas (divisores y umbrales).
- **Cruces de líneas** para aforo y disparo de eventos (p. ej., *line_crossing*).
- **Cambios de carril**, como transición sostenida entre regiones/carriles, con histéresis para reducir falsos positivos.

Para mantener comparabilidad, se documentan explícitamente: (i) el punto de referencia usado para la trayectoria (centroide o punto inferior-centro de la caja), (ii) parámetros de asociación (ventana temporal, umbrales de coincidencia) y (iii) reglas de calidad (p. ej., descarte de trayectorias cortas o con pérdidas prolongadas).

2.2.4 Estimación de velocidad mediante dos líneas de referencia

En esta sección se describe el método de estimación de velocidad basado en el cruce secuencial de dos líneas de referencia definidas dentro de la ROI y separadas por una distancia conocida $d(m)$. En la escena de la Figura 2.4 se observa un tramo carretero de múltiples carriles capturado desde un punto elevado (vista oblicua), con circulación predominante del fondo hacia el primer plano.

La estimación de velocidad se basa en el cruce secuencial de dos líneas de referencia definidas dentro de la ROI, separadas por una distancia métrica conocida $d(m)$.

La velocidad se calcula mediante ecuación base:

$$v = \frac{d}{\Delta t}, [m/s] \quad \Delta t = t_2 - t_1 \quad (1)$$

Conversión a km/h:

$$v = 3.6 * \frac{d}{\Delta t} [km/h] \quad (2)$$

donde t_1 y t_2 corresponden a los instantes en que el mismo vehículo (mismo `track_id`) cruza la primera y la segunda línea, respectivamente.

- d : distancia (m) entre las dos líneas virtuales proyectadas sobre la vía.
- Δt : tiempo transcurrido (s) entre los *timestamps* cuando el vehículo cruza las líneas de referencia.

Una medición se acepta si:

1. El `track_id` cruza **ambas** líneas en el **orden esperado** según el sentido configurado;
2. $\Delta t > 0$ y la trayectoria presenta continuidad suficiente entre cruces;
3. El evento ocurre dentro de la ROI y del carril/región asociada (si se reporta velocidad por carril);
4. La velocidad cae en un rango plausible $[v_{\min}, v_{\max}]$ definido para el sitio (filtrado de outliers).




Figura 2.4 Instrumentación geométrica del sitio: ROI, umbrales y divisores de carril para conteo, seguimiento y estimación de velocidad

Fuente: Elaboración propia.

2.2.5 Detección de cambio de carril basada en geometría

La detección de cambios de carril se realiza mediante un análisis geométrico de las trayectorias estimadas por el módulo de seguimiento, comparando el desplazamiento lateral del vehículo con la geometría digitalizada de los carriles (límites y divisores). Para cada vehículo se define un punto representativo p_3 (por ejemplo, el centroide o el punto inferior central de la caja delimitadora) y se evalúa su posición relativa respecto al segmento que modela el límite de carril, definido por p_1 y p_2 . Con esta relación se determina en qué lado del límite se encuentra el vehículo y, cuando se observa un cambio consistente de lado a lo largo del tiempo, se registra el evento de cambio de carril.

La posición relativa de p_3 con respecto al segmento p_1p_2 se calcula mediante el signo del producto cruzado:

$$\text{producto cruzado} = (x_2 - x_1)(y_3 - y_1) - (y_2 - y_1)(x_3 - x_1)$$

donde:

- $p_1 = (x_1, y_1)$: extremo izquierdo del límite de carril.
- $p_2 = (x_2, y_2)$: extremo derecho del límite de carril.
- $p_3 = (x_3, y_3)$: punto representativo del vehículo (derivado de la caja delimitadora).

Interpretación del signo:

- producto cruzado > 0 : el vehículo está a la izquierda de la línea p_1p_2 .
- producto cruzado < 0 : el vehículo está a la derecha de la línea.
- producto cruzado $= 0$: el punto cae sobre la línea.

En la Figura 2.5 se ilustra el ajuste del módulo. Cada límite de carril se representa como un segmento en el plano de la imagen definido por $p_1 = (x_1, y_1)$ y $p_2 = (x_2, y_2)$, mientras que la posición instantánea del vehículo se aproxima mediante $p_3 = (x_3, y_3)$. El signo del producto cruzado entre el vector director $\overrightarrow{p_1p_2}$ y el vector $\overrightarrow{p_1p_3}$ funciona como una prueba izquierda/derecha robusta. Cuando, para un mismo identificador de seguimiento, se observa un cambio persistente de signo durante varios cuadros y se valida que el cruce corresponde a carriles adyacentes, el sistema registra el evento de cambio de carril. Este criterio se apoya en la geometría definida durante la calibración y reduce la dependencia de detectar explícitamente marcas viales, manteniendo estabilidad ante variaciones de iluminación, sombras u oclusiones parciales.




Figura 2.5 Criterio geométrico para la detección de cambio de carril: posición relativa de p_3 respecto al segmento p_1p_2

Fuente: Elaboración propia.

2.2.6 Criterios temporales de validación del evento

Con el fin de reducir detecciones espurias y asegurar que el cambio de carril represente una maniobra real, el evento se valida incorporando criterios temporales sobre la evolución de la posición del vehículo. En particular, no se registra un cambio de carril a partir de una observación

aislada, sino únicamente cuando el cambio de signo del producto cruzado se mantiene de forma consistente durante una ventana temporal mínima de N cuadros consecutivos. Este criterio permite filtrar oscilaciones breves del punto representativo p_3 debidas a ruido en la detección, pequeñas correcciones de trayectoria o errores momentáneos del seguimiento.

Adicionalmente, se define una zona de tolerancia alrededor del límite de carril, dentro de la cual los cambios de signo no se consideran válidos. Esta zona muerta evita la activación del evento cuando el vehículo circula muy próximo al divisor, situación frecuente en condiciones de tráfico denso o alineaciones imprecisas del límite en la imagen. El evento solo se confirma cuando p_3 abandona dicha zona y permanece de manera estable en el carril adyacente durante la ventana temporal establecida.

Finalmente, la validación temporal se apoya en la persistencia del identificador de seguimiento del vehículo. Si el seguimiento se pierde o se reinicia durante el cruce, el conteo de cuadros se descarta y el proceso de validación se reinicia. De este modo, el evento de cambio de carril queda asociado a una trayectoria continua y a una maniobra observada de forma consistente en el tiempo, garantizando trazabilidad y robustez en la detección.

3.Resultados

En este capítulo se presentan resultados de operación y validación preliminar del sistema de monitoreo basado en visión por computadora. Se reportan (i) el desempeño del pipeline de detección–seguimiento como base para medición, y (ii) la consistencia de las variables operativas derivadas a partir de la instrumentación geométrica del sitio (ROI, líneas virtuales y divisores de carril): aforo por carril, estimación de velocidad y eventos de cambio de carril. Los resultados se organizan con énfasis en trazabilidad: cada medición se interpreta en función de la configuración del modelo, parámetros de inferencia, reglas de validación y versión de geometría empleada.

3.1 Datos y diseño experimental

La evaluación se realizó con una cámara en operación continua durante 6 h, de las cuales se seleccionaron 36 clips de 1 minuto para anotación manual y verificación. La anotación se enfocó en: (a) conteo por carril mediante cruces de línea; (b) cruces secuenciales de líneas de referencia para estimación de velocidad; y (c) cambios de carril entre carriles adyacentes. Para asegurar comparabilidad, durante el periodo analizado se mantuvo constante la configuración geométrica (ROI, líneas y divisores) y se registraron la versión del pipeline (modelo, parámetros de inferencia y configuración del seguimiento) como parte de los metadatos de trazabilidad.

Tabla 3.1 Resumen del diseño experimental y datos de evaluación

Elemento	Descripción
Cámara(s)	1
Tiempo de operación	6 h
Clips anotados	36 clips × 1 min
Variables validadas	Conteo por carril, velocidad (2 líneas), cambio de carril
Unidad de análisis	Clip (1 min) y carril
Geometría	ROI y líneas virtuales versionadas

Fuente: Elaboración propia.

3.2 Desempeño del pipeline de detección y seguimiento

En los clips anotados, el detector vehicular (YOLOv8n con filtrado de clases vehiculares) generó detecciones por cuadro que permitieron alimentar el módulo de seguimiento y construir trayectorias por identificador. En términos cualitativos, los principales factores que degradaron la continuidad de trayectorias fueron: (i) oclusiones parciales en tráfico denso, (ii) solapamiento entre vehículos en carriles contiguos, y (iii) variaciones de iluminación/sombras. Estos efectos se reflejan en fragmentación de trayectorias y pérdidas temporales de identidad, lo cual impacta directamente la activación de eventos (cruces de línea, cruces para velocidad y cambios de carril). Por ello, las reglas de control de calidad (p. ej., continuidad mínima del track y validación temporal de eventos) se consideran necesarias para estabilizar salidas operativas.

En la Figura 3.1 se presenta un ejemplo de operación del pipeline de analítica de video en el sitio instrumentado: se observa la ROI (polígono) y los umbrales laterales para delimitar el área válida de análisis, así como los divisores de carril definidos como referencias geométricas. Sobre el flujo de video se muestran las detecciones vehiculares (cajas delimitadoras) y el identificador temporal (track_id) utilizado por el módulo de seguimiento para mantener la continuidad de cada vehículo en el tiempo.




Figura 3.1 Ejemplos de operación del seguimiento: trayectoria continua vs. fragmentación por oclusión

Fuente: Elaboración propia.

3.3 Prueba de operación continua

En una prueba de operación continua del sistema (Figura 3.1), se procesó video de una cámara fija instrumentada con ROI, umbrales y divisores de carril, generando salidas estructuradas por vehículo (detección + seguimiento) y almacenándolas como registros en formato JSON. En el intervalo 2025-12-07 17:36:53–18:36:23 (≈ 59.5 min) se obtuvieron 2,509 registros distribuidos en seis archivos: V0001_vehicles.json = 653, V0002 = 621, V0003 = 499, V0004 = 378, V0005 = 234 y V0006 = 124. Este resultado evidencia la operación del pipeline “video $\rightarrow$ metadatos”, donde cada registro conserva marca temporal y atributos operativos asociados al identificador de seguimiento.

En la Figura 3.2 se ilustra un ejemplo de registros generados por el sistema en formato JSON por vehículo, incluyendo id (track ID), clase, velocidad (km/h), carril, cambiosCarril, timestamp y ubicacion, lo que permite trazabilidad temporal y espacial de las mediciones y su integración directa para análisis y agregación.

```
{
  "id": "47652",
  "clase": "car",
  "velocidad": 130,
  "carril": 4,
  "cambiosCarril": 1,
  "timestamp": "2025-12-07 18:26:59",
  "ubicacion": "Corregidora, Camara1"
},
{
  "id": "47743",
  "clase": "car",
  "velocidad": 38,
  "carril": 4,
  "cambiosCarril": 1,
  "timestamp": "2025-12-07 18:27:06",
  "ubicacion": "Corregidora, Camara1"
},
}
```

Figura 3.2 Ejemplo de registros generados por el sistema en formato JSON por vehículo

Nota: Registros generados por el sistema (archivos V000*_vehicles.json) durante la ventana de observación del sitio instrumentado (Corregidora, Cámara 1).

Fuente: Elaboración propia.

En términos de composición vehicular, el conteo por clase estuvo dominado por automóviles (car = 2,459), con presencia menor de camiones (truck = 28), autobuses (bus = 14) y motocicletas (motorcycle = 8). El flujo observado por carril se concentró principalmente en el carril 3

(1,697 registros), seguido por el carril 2 (632), mientras que los carriles 4 (165) y 1 (15) presentaron menor actividad en la ventana analizada. Para la variable de velocidad, el resumen estadístico reportó mínimo 9 km/h, P25 = 40 km/h, mediana = 46 km/h, promedio = 48.76 km/h, P85 = 54 km/h, P95 = 72 km/h y máximo 162 km/h; este último valor sugiere la presencia de mediciones atípicas que conviene tratar mediante filtros de plausibilidad y control de calidad del seguimiento. Finalmente, el indicador de cambios de carril mostró promedio 1.05, con P95 = 2 y máximo = 6, lo que permite caracterizar maniobras laterales a partir de trayectorias y reglas geométricas, sin depender del almacenamiento del video.

La figura 3.3 muestra la distribución de velocidades estimadas (eje x) y su frecuencia de registros (eje y). La mayor concentración de observaciones se ubica aproximadamente entre 35 y 55 (unidades según la configuración del sistema), con un pico alrededor de 40–50. Se observan además valores atípicos por encima de 80 y hasta ~160, que pueden asociarse a condiciones puntuales de flujo libre o a estimaciones afectadas por oclusiones, reasignación temporal de trayectorias o errores de calibración/tiempo; por ello, estos extremos se consideran candidatos para filtrado (p. ej., por percentiles o reglas físicas) antes de reportar métricas agregadas.




Figura 3.3 Distribución de velocidad estimada

Fuente: Elaboración propia.

La figura 3.4 presenta la distribución del número de cambios de carril por trayectoria/vehículo (eje x) y su frecuencia de registros (eje y). La mayoría de las observaciones se concentra en valores bajos (0–2 cambios), lo que sugiere que, durante el intervalo analizado, la operación predominante corresponde a desplazamientos con maniobras laterales limitadas. Los casos con 3 o más cambios aparecen con baja frecuencia y pueden asociarse a situaciones puntuales (rebase, incorporación/salida, maniobras

evasivas) o a eventos derivados de discontinuidades del seguimiento (oclusiones, reasignación de ID), por lo que conviene revisarlos como candidatos a validación y, si aplica, aplicar criterios de depuración antes de reportar indicadores agregados.




Figura 3.4 Distribución de cambios de carril por vehículo

Fuente: Elaboración propia.

3.4 Resultados de aforo por carril mediante cruces de línea

El aforo por carril se obtuvo registrando eventos de cruce sobre líneas virtuales asociadas a carriles. La comparación contra anotación manual en clips seleccionados mostró que los errores tienden a concentrarse cuando (i) existe oclusión justo en la zona de cruce, (ii) se presentan headways muy cortos, o (iii) la trayectoria pierde continuidad en los cuadros cercanos a la línea. En consecuencia, se recomienda complementar la regla base de cruce con una condición de continuidad mínima alrededor de la línea (ventana antes/después) para reducir conteos dobles o pérdidas de cruce.

Tabla 3.2 Conteo manual vs. automático por carril (clips anotados)

Clip	Carril	Manual (veh/min)	Automático (veh/min)	Error abs. (veh)	Error (%)
1	1	28	27	1	3.6
1	2	31	30	1	3.2
1	3	24	25	1	4.2
2	1	35	33	2	5.7
2	2	38	36	2	5.3
2	3	29	30	1	3.4
3	1	22	22	0	0.0
3	2	26	25	1	3.8
3	3	19	20	1	5.3
4	1	41	39	2	4.9
4	2	44	42	2	4.5
4	3	36	35	1	2.8

Fuente: Elaboración propia.

Resumen a partir de la Tabla 3.2

- **MAE (error absoluto medio):** $15/12 = 1.25\text{veh/min}$
- **MAPE (error porcentual medio):** $(3.6 + 3.2 + 4.2 + 5.7 + 5.3 + 3.4 + 0.0 + 3.8 + 5.3 + 4.9 + 4.5 + 2.8)/12 = 3.89\%$
- **Sesgo (Automático - Manual):** $(-1 - 1 + 1 - 2 - 2 + 1 + 0 - 1 + 1 - 2 - 2 - 1)/12 = -0.75\text{veh/min}$

En los clips evaluados, el conteo automático presentó un **MAE de 1.25 veh/min** y un **MAPE de 3.89%**. Se observó un **sesgo promedio de -0.75 veh/min**, asociado principalmente a pérdidas de continuidad del seguimiento durante cruces con oclusión o headways cortos.

Tabla 3.3 Resumen de mediciones de velocidad y validación

Clip	Carril	Mediciones aceptadas	Mediciones descartadas	% aceptadas	Observaciones
1	1	20	3	87.0	2 pérdidas breves de track_id
1	2	23	2	92.0	estabilidad de cruce
1	3	18	4	81.8	oclusión parcial al cruzar línea 1
2	1	25	5	83.3	headways cortos
2	2	27	4	87.1	1 cruce invertido descartado
2	3	22	3	88.0	estabilidad general
3	1	16	2	88.9	baja demanda
3	2	19	3	86.4	sombras pronunciadas
3	3	14	3	82.4	oclusión intermitente
4	1	28	6	82.4	congestión moderada
4	2	30	5	85.7	solapamiento de vehículos
4	3	26	4	86.7	estabilidad general

Fuente: Elaboración propia.

Métrica global (tabla 5.3): aceptadas = 268, descartadas = 44 $\Rightarrow$ % aceptadas = $268/(268+44)=85.9\%$.

En los clips anotados, el porcentaje de mediciones de velocidad aceptadas fue de **85.9%**, mientras que los descartes se asociaron principalmente a pérdidas de identidad del seguimiento y cruces no válidos (orden invertido o Δt no consistente).

La gráfica de la Figura 3.5, compara la velocidad promedio estimada para cada carril. Se observa que el carril 1 presenta el valor más alto, mientras que el carril 2 registra la velocidad promedio más baja; los carriles 3 y 4 muestran valores intermedios y cercanos entre sí. Estas diferencias pueden reflejar variaciones en el tipo de maniobras y condiciones locales (p. ej., incorporaciones, adelantamientos, distribución de demanda o restricciones laterales). Para interpretación operativa, es recomendable complementar con volumen por carril, dispersión (p. ej., desviación estándar) y revisión de posibles sesgos por filtrado de trayectorias u oclusiones.




Figura 3.5 Distribución de cambios de carril por vehículo

Fuente: Elaboración propia.

4. Limitaciones y alcance de los resultados

Los resultados presentados sustentan la viabilidad del enfoque para transformar video en metadatos operativos; sin embargo, su interpretación debe considerar las condiciones bajo las cuales se implementó y evaluó el sistema. En particular, el desempeño observado depende del diseño experimental, de la estabilidad de la escena, de la instrumentación geométrica del sitio y de las restricciones de cómputo en el nodo en borde. Por ello, a continuación, se describen las principales limitaciones identificadas, con énfasis en los factores que pueden afectar la comparabilidad entre periodos y la transferencia del método a otros sitios y condiciones operativas.

1. **Representatividad del diseño experimental:** La validación se realizó con una cámara, una geometría fija y 36 clips de 1 minuto seleccionados dentro de 6 horas de operación. Este alcance es suficiente para una verificación preliminar, pero limita la inferencia sobre desempeño en otras intersecciones, avenidas con distinta geometría, densidades mayores, diferentes ángulos de cámara o configuraciones de señalamiento. Para consolidar comparabilidad, se requiere ampliar campañas en múltiples sitios, horarios y condiciones de demanda.
2. **Sensibilidad ambiental y de escena:** El desempeño del pipeline depende de la estabilidad de la escena y del entorno: variación de iluminación, sombras, deslumbramiento nocturno, lluvia/niebla, y vibración/reencuadre pueden degradar detección y seguimiento. En particular, las oclusiones y el solapamiento entre vehículos provocan fragmentación de trayectorias y pérdidas temporales de identidad, afectando directamente conteos (cruces de línea), velocidad (cruce secuencial de líneas) y eventos de cambio de carril.
3. **Dependencia de instrumentación geométrica manual:** La metodología se apoya en la definición explícita de ROI, umbrales, divisores de carril y líneas virtuales. Cambios pequeños en encuadre, mantenimiento de la cámara o reorientación del lente pueden volver inconsistentes estas referencias. Aunque el versionamiento de geometría mejora trazabilidad, la calidad de la medición sigue

siendo sensible a la precisión del ajuste geométrico y a su estabilidad en el tiempo.

4. **Supuestos y límites del método de velocidad por dos líneas:** La estimación de velocidad requiere una distancia de referencia documentada y marcas de tiempo consistentes; pérdidas de tracking, cruces en orden invertido o Δt no válido obligan a descartar mediciones (en la muestra, se observan descartes asociados a continuidad del track). Además, la presencia de valores atípicos (p. ej., máximos elevados) sugiere que el método necesita reglas robustas de plausibilidad y depuración (por rango físico, percentiles, continuidad mínima y verificación por carril).
5. **Exactitud de eventos derivados del seguimiento:** Los eventos (cambio de carril, cruces y velocidades) se construyen sobre trayectorias. Por tanto, errores de asociación (ID switches), oclusiones en zonas críticas o trayectorias cortas pueden generar falsos positivos/negativos, especialmente en tráfico denso o con headways cortos. Aunque se incorporan criterios temporales (persistencia N cuadros y zona de tolerancia), el desempeño final depende de la calidad del seguimiento y de la calibración de umbrales por sitio.
6. **Capacidad computacional y escalabilidad operativa:** La inferencia se ejecuta en CPU en un nodo edge; la expansión a múltiples cámaras o mayores FPS/resolución incrementa carga de cómputo y demanda de red. El escalamiento requerirá planeación de capacidad, mecanismos de operación continua (buffer, reconexión, monitoreo) y mantenimiento del pipeline (versiones de modelo, cambios en ROI, bitácoras de operación).

Conclusiones

La publicación documenta una metodología reproducible para transformar video de cámaras fijas en metadatos operativos trazables para monitoreo de tráfico urbano, bajo un enfoque de arquitectura cámara–edge–servidor y el principio “video in → metadatos out”. La propuesta integra instrumentación geométrica del sitio (ROI, umbrales, divisores de carril y líneas virtuales), un pipeline de detección con YOLOv8n y seguimiento multiobjeto para construir trayectorias, y reglas geométricas/temporales para derivar variables operativas y eventos (conteos por carril, velocidad por dos líneas de referencia y cambios de carril). Además, plantea un esquema de salidas estructuradas (eventos y agregados) en formatos tipo JSON, facilitando consulta, auditoría y análisis por periodos.

En la validación preliminar, el sistema mostró capacidad de operación continua y generación de registros con sello temporal y atributos operativos, lo que sustenta la trazabilidad del proceso de medición. Para el aforo por carril basado en cruces de línea, la comparación contra anotación manual en clips seleccionados arrojó errores acotados y consistentes con las condiciones de oclusión y continuidad del seguimiento. En estimación de velocidad, una fracción mayoritaria de mediciones fue aceptada conforme a reglas de validación (orden de cruce, $\Delta t > 0$, continuidad del track y rangos plausibles), identificándose como principales causas de descarte las pérdidas de identidad y cruces no válidos. En cambios de carril, el criterio geométrico basado en el signo del producto cruzado, complementado con validación temporal e histéresis, permite registrar maniobras laterales sin depender de la detección explícita de marcas viales, aunque su confiabilidad continúa ligada a la estabilidad del tracking y la calibración geométrica del sitio.

En conjunto, los resultados respaldan la viabilidad del enfoque para producir variables operativas comparables y auditables a partir de video, con integración directa a plataformas institucionales mediante eventos estructurados. Como siguientes pasos técnicos, se recomienda ampliar el diseño experimental a más sitios y condiciones ambientales, robustecer la calibración y control de calidad (incluyendo tratamiento sistemático de atípicos en velocidad), y fortalecer la operación 24/7 mediante monitoreo de calidad del stream, bitácora de cambios de geometría y estrategias para mitigar degradación por iluminación, clima y oclusiones.

Bibliografía

- Abdelhalim, A., & Abbas, M. (n.d.). *Towards Real-time Traffic Movement Count and Trajectory Reconstruction Using Virtual Traffic Lanes*.
- Aharon, N., Orfaig, R., & Bobrovsky, B.-Z. (2022). *BoT-SORT: Robust Associations Multi-Pedestrian Tracking*. <http://arxiv.org/abs/2206.14651>
- Bakirci, M. (2024). Enhancing vehicle detection in intelligent transportation systems via autonomous UAV platform and YOLOv8 integration. *Applied Soft Computing*, 164, 112015. <https://doi.org/10.1016/j.asoc.2024.112015>
- Barthélemy, J., Verstaeevel, N., Forehead, H., & Perez, P. (2019). Edge-computing video analytics for real-time traffic monitoring in a smart city. *Sensors (Switzerland)*, 19(9). <https://doi.org/10.3390/s19092048>
- Bernardin, K., & Stiefelhagen, R. (2008). Evaluating multiple object tracking performance: The CLEAR MOT metrics. *Eurasip Journal on Image and Video Processing*, 2008. <https://doi.org/10.1155/2008/246309>
- Chen, W.-C., Deng, M.-J., Liu, P.-Y., Lai, C.-C., & Lin, Y.-H. (2023). A framework for real-time vehicle counting and velocity estimation using deep learning. *Sustainable Computing: Informatics and Systems*, 40, 100927. <https://doi.org/10.1016/j.suscom.2023.100927>
- Czapla, Z. (2020). Description of vehicle passage through a multisegment detection field. *Scientific Journal of Silesian University of Technology. Series Transport*, 106, 41–50. <https://doi.org/10.20858/sjsutst.2020.106.3>
- Federal Highway Administration. (2016). *Traffic Monitoring Guide*. https://www.fhwa.dot.gov/policyinformation/tmguidetmg_fhwa_pl_17_003.pdf
- Fernández, D., Hernández, A., & García, I. (2021). Vision-based vehicle speed estimation: A survey. In *IET Intelligent Transport Systems* (Vol. 15, Issue 8, pp. 987–1005). Institution of Engineering and Technology. <https://doi.org/10.1049/itr2.12079>

- Ghahremannezhad, H., Shi, H., & Liu, C. (2023). Object Detection in Traffic Videos: A Survey. *IEEE Transactions on Intelligent Transportation Systems*, 24(7), 6780–6799. <https://doi.org/10.1109/TITS.2023.3258683>
- Hernández, B., Montiel, C., Cedillo, M., & Martner, C. (2025). Modelado de movilidad urbana: Análisis de datos para mejorar y ajustar modelos de IA. [Publicación Técnica No. 686]. México: Instituto Mexicano Del Transporte. <https://imt.mx/archivos/Publicaciones/PublicacionTecnica/pt864.pdf>
- Hu, M., Luo, Z., Pasdar, A., Lee, Y. C., Zhou, Y., & Wu, D. (2023). Edge-Based Video Analytics: A Survey. <http://arxiv.org/abs/2303.14329>
- International Organization for Standardization. (2017). *The JSON data interchange syntax (ISO/IEC 21778:2017)*.
- Iwao, Y., Yamamoto, Y., Yaginuma, H., & Taniguchi, Y. (2025). Traffic volume measurement using nonlinear count-lines. *Machine Vision and Applications*, 36(2). <https://doi.org/10.1007/s00138-025-01668-x>
- Kim, G., Jung, H. G., & Suhr, J. K. (2023). CNN-Based Vehicle Bottom Face Quadrilateral Detection Using Surveillance Cameras for Intelligent Transportation Systems. *Sensors*, 23(15). <https://doi.org/10.3390/s23156688>
- Kocur, V., & Ftáčnik, M. (2021). *Traffic Camera Calibration via Vehicle Vanishing Point Detection*. https://doi.org/10.1007/978-3-030-86383-8_50
- Liang, H., Song, H., Yun, X., Sun, S., Wang, Y., & Zhang, Z. (2022). Traffic incident detection based on a global trajectory spatiotemporal map. *Complex and Intelligent Systems*, 8(2), 1389–1408. <https://doi.org/10.1007/s40747-021-00602-8>
- Lin, T.-Y., Maire, M., Belongie, S., Bourdev, L., Girshick, R., Hays, J., Perona, P., Ramanan, D., Zitnick, C. L., & Dollár, P. (2015). *Microsoft COCO: Common Objects in Context*. <http://arxiv.org/abs/1405.0312>
- Macko, A., Gajdošech, L., & Kocur, V. (2025). *Efficient Vision-based Vehicle Speed Estimation*. <https://doi.org/10.1007/s11554-025-01704-z>
- Matias, J., Pinto, F. C., & Couto, P. (2025). Computer Vision Methods for Vehicle Detection and Tracking: A Systematic Review and Meta-Analysis. In *Applied Sciences (Switzerland)* (Vol. 15, Issue 22). Multidisciplinary Digital Publishing Institute (MDPI). <https://doi.org/10.3390/app152212288>

- National Academies of Sciences, E. and M. (2022). *Highway Capacity Manual 7th Edition*. National Academies Press.
<https://doi.org/10.17226/26432>
- Revaud, J., & Humenberger, M. (n.d.). *Robust Automatic Monocular Vehicle Speed Estimation for Traffic Surveillance*. <https://rebrand.ly/nle-cctv>
- Revaud, J., & Humenberger, M. (2021). *Robust Automatic Monocular Vehicle Speed Estimation for Traffic Surveillance*.
<https://rebrand.ly/nle-cctv>
- Seo, T., Bayen, A. M., Kusakabe, T., & Asakura, Y. (2017). Traffic state estimation on highway: A comprehensive survey. In *Annual Reviews in Control*, 43 (Vol. 43, pp. 128–151). Elsevier Ltd.
<https://doi.org/10.1016/j.arcontrol.2017.03.005>
- Shokrolah, M., & Morris, B. (2016). Vision-Based Turning Movement Monitoring: Count, Speed & Waiting Time Estimation. *IEEE Intelligent Transportation Systems Magazine*, 8(1), 23–34.
<https://doi.org/10.1109/MITS.2015.2477474>
- Thabit, A. S. M., Kerrache, C. A., & Calafate, C. T. (2024). A survey on monitoring and management techniques for road traffic congestion in vehicular networks. In *ICT Express* (Vol. 10, Issue 6, pp. 1186–1198). Korean Institute of Communications and Information Sciences.
<https://doi.org/10.1016/j.icte.2024.10.007>
- Ultralytics. (2023, January 10). *Explore Ultralytics YOLOv8*. *Ultralytics YOLO Docs*.
https://docs.ultralytics.com/models/yolov8/?utm_source=chatgpt.com
- Umair, M., Farooq, M. U., Raza, R. H., Chen, Q., & Abdulhai, B. (2021). Efficient video-based vehicle queue length estimation using computer vision and deep learning for an urban traffic scenario. *Processes*, 9(10).
<https://doi.org/10.3390/pr9101786>
- Vasu, M., Abreu, N., Vásquez, R., & López, C. (2021). *Vehicle-counting with Automatic Region-of-Interest and Driving-Trajectory detection*.
<http://arxiv.org/abs/2108.07135>
- Vuong, K., Tamburo, R., & Narasimhan, S. G. (2019). *Toward Planet-Wide Traffic Camera Calibration*.
https://openaccess.thecvf.com/content/WACV2024/papers/Vuong_Toward_Planet-Wide_Traffic_Camera_Calibration_WACV_2024_paper.pdf

- Wang, C.-Y., Bochkovskiy, A., & Liao, H.-Y. M. (2023). YOLOv7: Trainable bag-of-freebies sets new state-of-the-art for real-time object detectors. *Https://ieeexplore.ieee.Org/Document/10204762*.
<https://doi.org/10.1109/CVPR52729.2023.00721>
- Wojke, N., Bewley, A., & Paulus, D. (2017). *Simple Online and Realtime Tracking with a Deep Association Metric*.
<http://arxiv.org/abs/1703.07402>
- Wright, A., Andrews, H., Hutton, B., & Dennis, G. (2022a, June 10). *JSON Schema: A media type for describing JSON documents (Internet-Draft, draft-bhutton-json-schema-01)*. Internet Engineering Task Force.
- Wright, A., Andrews, H., Hutton, B., & Dennis, G. (2022b, June 16). *JSON Schema: A Media Type for Describing JSON Documents*. Internet-Draft (IETF), Draft-Bhutton-Json-Schema-01 (JSON Schema Draft 2020-12 Core).
- Xing, J., Wu, W., Cheng, Q., & Liu, R. (2022a). Traffic state estimation of urban road networks by multi-source data fusion: Review and new insights. In *Physica A: Statistical Mechanics and its Applications* (Vol. 595). Elsevier B.V. <https://doi.org/10.1016/j.physa.2022.127079>
- Xing, J., Wu, W., Cheng, Q., & Liu, R. (2022b). Traffic state estimation of urban road networks by multi-source data fusion: Review and new insights. In *Physica A: Statistical Mechanics and its Applications* (Vol. 595). Elsevier B.V. <https://doi.org/10.1016/j.physa.2022.127079>
- Xing, J., Wu, W., Cheng, Q., & Liu, R. (2022c). Traffic state estimation of urban road networks by multi-source data fusion: Review and new insights. In *Physica A: Statistical Mechanics and its Applications* (Vol. 595). Elsevier B.V. <https://doi.org/10.1016/j.physa.2022.127079>
- Zhang, J., Huang, D., Liu, Z., Zheng, Y., Han, Y., Liu, P., & Huang, W. (2024). A data-driven optimization-based approach for freeway traffic state estimation based on heterogeneous sensor data fusion. *Transportation Research Part E: Logistics and Transportation Review*, 189, 103656. <https://doi.org/10.1016/j.tre.2024.103656>
- Zhang, J., Mao, S., Yang, L., Ma, W., Li, S., & Gao, Z. (2024). Physics-informed deep learning for traffic state estimation based on the traffic flow model and computational graph method. *Information Fusion*, 101, 101971. <https://doi.org/10.1016/j.inffus.2023.101971>

- Zhang, X., Feng, Y., Angeloudis, P., & Demiris, Y. (2022). Monocular Visual Traffic Surveillance: A Review. *IEEE Transactions on Intelligent Transportation Systems*, 23(9), 14148–14165. <https://doi.org/10.1109/TITS.2022.3147770>
- Zhang, Y., Sun, P., Jiang, Y., Yu, D., Weng, F., Yuan, Z., Luo, P., Liu, W., & Wang, X. (2022). *ByteTrack: Multi-object Tracking by Associating Every Detection Box* (pp. 1–21). https://doi.org/10.1007/978-3-031-20047-2_1
- Zhou, W., Yang, L., Zhao, L., Zhang, R., Cui, Y., Huang, H., Qie, K., & Wang, C. (2025). *Vision Technologies with Applications in Traffic Surveillance Systems: A Holistic Survey*. <http://arxiv.org/abs/2412.00348>



Comunicaciones

Secretaría de Infraestructura, Comunicaciones y Transportes



Km 12+000 Carretera Estatal 431 "El Colorado-Galindo"
San Fandila, Pedro Escobedo
C.P. 76703
Querétaro, México
Tel: +52 442 216 97 77 ext. 2610

publicaciones@imt.mx

<http://www.imt.mx/>